




Análise e Visualização
de Dados



pandas
 $y_i t = \beta^T x_{it} + \mu_i + \epsilon_{it}$



TensorFlow Playground — Dataset Spiral

Experimento com Redes Neurais: impacto da arquitetura, ativação e hiperparametros

1. Objetivo



Utilizando apenas as entradas **x1** e **x2** no TensorFlow Playground (playground.tensorflow.org), explorar diferentes configurações de redes neurais para classificar o dataset **Spiral** com **perda de teste abaixo de 0,1**. O dataset Spiral é considerado o mais difícil dos conjuntos sintéticos disponíveis, pois as duas classes formam espirais entrelaçadas que nenhuma fronteira linear consegue separar.

2. Configuração Final (Perda de Teste: 0,07)

Configuração da Rede Neural — Spiral Dataset

Entradas	x1, x2 apenas	sem features polinomiais
Camadas escondidas	4 camadas	profundidade essencial para espiral
Neuronios por camada	8 → 8 → 6 → 4	pirâmide decrescente
Funcao de ativacao	ReLU	melhor convergencia que Sigmoid
Taxa de aprendizagem	0,03	lr baixa = convergencia estavel
Regularização	L2 — lambda = 0,001	evita overfitting
Epocas (aprox.)	~1500	convergencia completa
Perda de Teste	0,07	abaixo da meta de 0,1

3. Visualização — Fronteira de Decisão e Arquitetura



Esquerda: fronteira de decisão aprendida (pontos vermelhos e azuis = classes da espiral).

Direita: arquitetura com 4 camadas escondidas e ativação ReLU.

0,07

Perda de Teste

~97%

Acurácia

4

Camadas

~1500

Épocas

4. Experimentos Realizados — Comparativo de Configuração

A tabela abaixo resume as principais configurações testadas, do mais simples ao mais eficaz. Todas usam apenas x1 e x2 como entradas.

Config.	Camadas	Neurónios	Ativação	LR	Reg.	Perda Teste	Obs.
A	1	8	ReLU	0.03	Nao	0,49	Insuficiente
B	2	8-8	ReLU	0.03	Nao	0,31	Melhora parcial
C	2	8-8	Sigmoid	0.03	Nao	0,38	Sigmoid lenta
D	3	8-8-6	ReLU	0.03	Nao	0,19	Quase suficiente
E	3	8-8-6	ReLU	0.10	Nao	0,22	LR alta = instável
F	4	8-8-6-4	ReLU	0.03	L2 0.001	0,07	META ATINGIDA
G	4	16-16-8-4	ReLU	0.03	Nao	0,09	Overfitting leve
H	6	16-16-8-8-6-4	ReLU	0.01	L2 0.001	0,08	Mais lento, similar

5. O que aprendi — Análise dos Hiperparametros

Número de Camadas

O impacto mais crítico para o dataset Spiral. Com apenas 1 camada escondida (Config. A), a rede não consegue aprender a curvatura das espirais e a perda fica em ~0,49. Cada camada adicional permite que a rede aprenda representações mais abstratas dos dados. Com 4 camadas (Config. F), a fronteira de decisão consegue acompanhar as curvas das espirais e a perda cai para 0,07. O Spiral é um problema intrinsecamente não-linear e não-convexo — profundidade não é opcional, é obrigatória.

Número de Neurónios por Camada

Mais neurónios aumentam a capacidade de expressão de cada camada. Porem, há um ponto de retorno decrescente: passar de 8 para 16 neurónios (Config. G) não reduziu a perda significativamente, mas aumentou o risco de overfitting e o tempo de treinamento. A arquitetura em "piramide decrescente" (8→8→6→4) funcionou bem: as primeiras camadas capturam features brutas com mais neurónios; as últimas refinam a classificação com menos.

Função de Ativação — ReLU vs Sigmoid

A ReLU foi claramente superior para este problema. A Sigmoid (Config. C) convergiu muito mais devagar e atingiu perda final pior, mesmo com mais épocas. O motivo é o vanishing gradient: a Sigmoid satura para valores extremos (saída próxima de 0 ou 1), e o gradiente fica minúsculo nessas regiões. Em redes com 3-4 camadas, isso impede que as camadas iniciais aprendam. A ReLU não tem esse problema para valores positivos (gradiente = 1), tornando o treinamento muito mais eficaz.

Taxa de Aprendizagem (Learning Rate)

LR muito alta (0,10, Config. E): a perda oscilava e não convergia estavelmente — os passos do gradiente descendente eram grandes demais e "saltavam" sobre o mínimo. LR muito baixa (0,001): convergência correta, mas extremamente lenta. LR = 0,03 (Config. F): equilíbrio ideal — convergência estável e rápida o suficiente. A mensagem principal: a taxa de aprendizagem controla o tamanho do passo na descida do gradiente. Muito grande = instabilidade; muito pequena = demora excessiva.

Regularização (L2 — Weight Decay)

Sem regularização (Config. G), a rede com muitos neurónios tendia a "memorizar" o dataset em vez de generalizar — a fronteira de decisão ficava irregular e entortada. Com L2 ($\lambda=0,001$), os pesos são penalizados por serem grandes, incentivando soluções mais suaves e generalizáveis. O efeito visual é uma fronteira de decisão mais "limpa", e o efeito numérico é uma redução da diferença entre perda de treino e de teste.

6. Conclusão

O dataset Spiral demonstra de forma muito clara por que redes neurais profundas existem. Nenhuma combinação de features lineares (x_1 , x_2 sem transformações) consegue separar duas espirais entrelaçadas com uma única camada. A profundidade da rede — combinada com ativações não-lineares como ReLU — é o que permite aprender fronteiras de decisão arbitrariamente complexas. Os hiperparâmetros (LR, regularização, número de neurónios) refinam *como* esse aprendizado acontece: a taxa de aprendizagem controla a velocidade e estabilidade; a regularização controla a generalização; o número de neurónios controla a capacidade. A configuração final (4 camadas, ReLU, LR=0,03, L2=0,001) atingiu perda de teste de **0,07**, superando a meta de 0,1.